SÉANCE 01

PROJET FIL ROUGE

Projet fil rouge — Présentation générale : analyse de données météorologiques

Ce document ne contient pas d'exercice : il vous donne une vue d'ensemble du projet fil rouge mené sur les séances suivantes du module, avant que vous ne commenciez à le manipuler concrètement. Conservez-le, vous y reviendrez au fil du module.

Point de départ

Aucun : ce document ouvre le fil rouge du module. Il n'y a pas de travail à produire dessus aujourd'hui — vous ne manipulez le jeu de données réel qu'à partir de la prochaine séance, une fois les bases de lecture de fichiers consolidées.

Le projet en une phrase

Analyser un jeu de données météorologiques réelles, du chargement brut jusqu'à un modèle de régression simple prédisant la température, en utilisant progressivement les outils vus au fil du module (Python natif, numpy, pandas, matplotlib, scikit-learn).

Le jeu de données

- **Source :** *« Observation météorologique historiques France (SYNOP) »*, Météo-France, disponible sur data.gouv.fr (Licence Ouverte / Open Licence 2.0).
- **Contenu :** relevés au pas de temps de 3 heures, par station météo : température, pression, humidité, direction et vitesse du vent, hauteur de précipitations, nébulosité.
- **Station et période retenues pour ce module :** station **Lille-Lesquin** (indicatif OMM `07015`), période du 1er janvier au 31 décembre 2023.
- Un extrait déjà préparé pour cette station et cette période vous sera fourni au moment où vous en aurez besoin, dans le format brut Météo-France d'origine (séparateur `;`, valeurs manquantes codées `mq`, colonnes non filtrées) : vous travaillez sur des données réelles, pas sur une version simplifiée pour l'exercice.

Grandes étapes du projet

Le projet progresse par étapes, chacune s'appuyant sur le travail réalisé à la précédente :

- Chargement et nettoyage du jeu de données brut : repérage et traitement des valeurs manquantes, conversion des unités.
- Première exploration : agrégations simples (par mois, par heure) et visualisations pour se familiariser avec les données.
- Consolidation du script : restructuration en fonctions, gestion des erreurs courantes.
- Modélisation : mise en œuvre d'une régression simple (scikit-learn) prédisant la température, et interprétation critique du résultat.

Vous conserverez une version fonctionnelle de votre script d'une séance à l'autre : chaque nouvelle étape s'appuie directement sur le travail déjà produit, sans repartir de zéro.

Extension optionnelle

Pour les étudiants les plus à l'aise, vers la fin du module : croisement de la température moyenne journalière avec des données de consommation électrique, afin d'expliquer la consommation à partir de la température.

- **Source :** *« Électricité : consommation, production, CO2 et échanges »* (éCO2mix, RTE), disponible sur data.gouv.fr et opendata.reseaux-energies.fr (licence ouverte).